

Проекты Speech весна 2026								
Название	Ведёт	Тип проекта	Чат в ТГ (вступаем!)	Про что проект? Краткое описание сути и самый интересный момент в проекте	Что нужно будет сделать? Образ итогового результата	Основные этапы	Предварительные критерии оценивания	Ссылки на ресурсы для более подробного чтения
Speech-Toolformer	Анна Пиунова Георгий Апарин	Applied Science (исследовательско-прикладной)	https://t.me/+HmJQMapwDml4YiAy	Построим голосового ассистента на базе Gemma-3n (или LFM2-Audio/другой до ~4B) с поддержкой вызова инструментов: ассистент слушает запрос на русском или английском, решает, нужен ли вызов инструмента, выдает форматированный вызов (JSON/XML), бэкэнд выполняет его и возвращает обоснованный ответ текстом (или озвученный). Самое интересное: сравнить разные пайплайны работы со звуком (Audio - model - ASR - model - tool-call или Audio - model - tool-call и другие) и понять, сколько дообучения реально требуется, чтобы из речи стабильно получать корректные tool-calls.	Построение ассистента: - Ассистент должен принимать голосовой запрос (на русском или английском). - Понимать запрос напрямую из аудио. - Генерировать вызов инструмента (функции) в структурированном формате (JSON или XML). - Опционально выполнять инструмент и получать результат. - Формировать обоснованный, понятный человеку ответ (возможно, озвученный). Выбор модели: - Рекомендуется Gemma-3n E4B Instruct как нативно мультимодальная модель с поддержкой Function Calling. Если модель не справляется с русским языком, может потребоваться дообучение. - Альтернатива: LFM2-Audio-1.5B (меньше и не поддерживает русский, но может генерировать речь). Инструменты (Tool(s)): - Необходимо реализовать хотя бы один инструмент, НО не тот, что дан в примере (не погода) - Рекомендуется избегать инструментов со сложным парсингом или большим количеством аргументов. Подготовка данных и стратегия обучения: - Определение API инструмента: Выбрать простой интерфейс, формат вызова (JSON/XML) и описать схему в системном промпте. Генерация синтетического текстового датасета: - Создать 50-100 шаблонов на инструмент, сгенерировать 200–300 текстовых сообщений, определить ожидаемый вызов инструмента, сгенерировать финальный ответ. Добавить 10-20% примеров, не требующих инструмента. - Синтезировать аудио для каждого текстового запроса (например, с помощью Coqui TTS). Эксперименты и сравнение пайплайнов: Сравнить различные рабочие процессы: (A) Текст → Модель → Вызов инструмента (B) Аудио → Модель → Транскрипт ASR (C) Аудио → Модель → Транскрипт + Вызов инструмента за один проход (Joint pipeline) (D) Аудио → Модель → Транскрипт → Модель → Вызов инструмента (Cascaded pipeline) Оценить, какой объем дообучения требуется для каждого из них. Метрики и оценка: - Корректность вызова инструмента (на тексте): Precision, Recall, False Alarm Rate, Parsable Tool Invocation Rate. Требуется реализовать и оценить один из предложенных пайплайнов дублирования (Каскадная система ASR→MT→TTS, Speech-to-text translation→TTS или Speech-only end-to-end S2ST) или предложить свой.	Неделя 1 – База (промт-инжиниринг и тестирование) Загрузка модели. Тест промпта «вслепую» (zero-shot): аудио «Какая погода завтра в Казани?» → ожидается валидный вызов инструмента (tool_call). Реализация парсера (обнаружение/валидация JSON: одна попытка повтора в случае некорректного формата). Создание небольшого текстового набора данных (≥200) и запуск рабочих процессов только с текстом. Неделя 2 – Данные и первая оценка аудио Генерация аудио-набора данных с помощью TTS; измерение WER на подмножестве. Оценка различных рабочих процессов на аудио по сравнению с текстом; регистрация EM вызова инструмента (tool-call EM), доли парсируемых ответов, точности/полноты (precision/recall). Неделя 3 – Тьюнинг промптов и SFT на аудио При необходимости: точная настройка модели на текстовых данных (Text SFT) для улучшения форматирования/принятия решения о вызове инструмента. Повторная оценка метрик использования инструмента (текст и аудио), отчет о приросте и разрыве между модальностями. Опционально: небольшая точная настройка модели с учетом аудио (audio-conditioned SFT) для улучшения работы на русском языке. Добавление еще одного инструмента (например, units. convert или nlp.stress). Неделя 4 – Создание отчета и опционально рабочего процесса n8n Доработка демонстрационного ноутбука + отчета (результаты, анализ ошибок, выбор наилучшего рабочего процесса). Опционально: подготовка рабочего процесса n8n для демонстрации.	Креативность выбора инструмента (2 б.) System-prompt tuning и оценка модели на следование инструкциям (2 б.): чёткая схема инструмента определена; сделана оценка на тест-сете с примерами. Метрики по текстовому tool-use (пайплайн A) (3 б.): accuracy, precision/recall, false alarm rate, доля ответов модели, которые удается распарсить; корректная интерпретация результатов. Дизайн синтетического датасета (4 б.): понятное описание; сбалансированные текст+аудио; пример запросов «без инструмента»; ASR бенчмаркинг (пайплайн B) (3 б.): WER + короткий разбор ошибок Бенчмаркинг аудио пайплайнов C–D (3 б.) Выбор лучшего пайплайна (2 б.): обоснование выбора по метрикам. Финальный отчёт (3 б.): краткие выводы и фейл-кейсы	Видео презентация: speech_toolformer.pdf
Lecture Dubbing	Ибрагим Идрисов	Прикладной		Задача проекта - выбрать лекцию из курса DLS-Speech и создать убедительный дублированный на английский язык вариант, который останется синхронизированным с оригинальным видео. Синхронность означает, что длительность каждого сегмента речи в дуближе должна максимально соответствовать исходной. Самый интересный момент в проекте - необходимость реализовать пайплайн для точного контроля времени, чтобы дублированная речь не отставала от событий на экране (смены слайдов, жестов).	Требуется реализовать и оценить один из предложенных пайплайнов дублирования (Каскадная система ASR→MT→TTS, Speech-to-text translation→TTS или Speech-only end-to-end S2ST) или предложить свой.	Реализация выбранного пайплайна: - Получение надежных временных меток (таймстампов) из исходного аудио. - Сегментация аудио по естественным паузам (VAD) с сохранением исходной длительности. - Распознавание речи и перевод. - Синтез речи с помощью управляемого TTS, измерение длительности сгенерированных реплик и, при необходимости, выполнение микрокорректировки времени с помощью инструментов типа ffmpeg - Сборка дублированного аудио и финального видео	Оценка будет производиться по следующим критериям: - Техническая корректность и воспроизводимость (4 балла). - Качество тайминга и синхронизации (4 балла). - Объективные метрики и анализ (4 балла): COMET-QE/COMETKiwi для перевода, NISQA для качества речи. - Сведение аудио и общее качество просмотра (3 балла). - Сравнительный анализ и обоснование выбора подхода (5 баллов). Бонусные баллы: - Синхронизация движения губ (Mouth re-synchronization) (5 бонусных баллов). - Реализация и сравнение двух различных пайплайнов (8 бонусных баллов).	Описание проекта: lecture_dubbing.pdf
Low-resource ASR	Андрей Кузьменко		https://t.me/+S5Xo4whttps://t.me/tbwXYZEyGWdmYTJl	Разработать модель распознавания речи для low-resource языка из списка: белорусский, казахский, киргизский, узбекский, азербайджанский, татарский, туркменский, башкирский, таджикский, армянский (можно предложить свой). Девиз проекта - качаем модель за счет данных. Тратим много времени на сбор данных и очень мало на выбор модели (не пытаемся учить модель с нуля, а используем готовый ssl/модели близких языков), и еще меньше на обогащения различными надстройками, например лм-ки. Ваш датасет в идеале должен включать много различных доменов и форматов: 1) открытые данные, 2) аудиокнижки (CTC-Forced alignment); 3) синтетические данные; 4) псевдотексты.	Реализовать пайплайн обучения модели под low-resource язык. Обучить модель под low-resource язык. Собрать обучающую выборку. Результат: модель распознавания речи для low-resource языка.	На первой недели необходимо будет реализовать код обучения и инференса модели (можно взять из семинара/домашки по low-resource). Так, что можно было легко добавить новую пачку данных. Крайне не рекомендуется учить модель с нуля (используйте ssl претрениры или модели близких языков). На второй недели поиск общедоступных данных: asr-данных (пары аудио-транскрипции), моделей синтеза речи, моделей распознавания речи (которые можем файнтюнить или использовать для псевдотекстов) текстовых данных для синтеза речи, аудиокниг и др. Выбрать open source set, который будет являться нашим основным бенчмарком (именно его будем оптимизировать). Чистка собранных данных. Третью неделю посвятим поиску конфигурации обучения (гиперпараметров): скорость обучения, батч, веса датасетов. Четвертая неделя - финализация результатов (чистим ноутбуки от плохих экспериментов, комментируем что попробовали - что получили)	Реализация обучения модели под low resource язык на open source данных - 8б Сбор и подготовка аудио книг: 6б (CTC-Forced alignment) Подготовка синтетических данных: выбор модели с обоснованием, сбор текстовых данных. - 6б Подготовка псевдотекстов. - 10б (сильно зависит от сложности пайплайна псевдотекстов).	

			Самое интересное - проявить инженерные навыки; прощупать на практике наиболее времязатратную работу; убедиться, что качественные данные - важнее архитектуры модели.				
--	--	--	--	--	--	--	--